

Коментари:

$$\mathbb{E} \left[\sum_{j=1}^n X_j \right] = \sum_{j=1}^n \mathbb{E}[X_j], \text{ винаги (когато очакванията са добре дефинирани).}$$

$$\text{Var} \left[\sum_{j=1}^n X_j \right] = \sum_{j=1}^n \text{Var}[X_j], \text{ ако } X_1, X_2, \dots, X_n \text{ са независими в съвкупност.}$$

Целочислени случайни величини

Дефиниция (Схема на Бернули).

Схема на Бернули (или последователност на Бернули) е поредица от n независими опити, където всеки опит има само два възможни изхода:

1. **Успех** (Success) с вероятност p , където $0 \leq p \leq 1$
2. **Неуспех** (Failure) с вероятност $q = 1 - p$

Обикновено успехът се кодира като 1, а неуспехът като 0.

Нека имаме n случайни величини X_1, X_2, \dots, X_n , такива че:

- Всяка X_i има разпределение на Бернули: $X_i \sim \text{Bernoulli}(p)$
- Те са взаимно независими

Тогава векторът (X_1, X_2, \dots, X_n) описва схема на Бернули с параметри n и p .

(A) Разпределение на Бернули

$X \sim \text{Bernoulli}(p) \equiv \text{Ber}(p)$, ако имаме разпределението:

$$X_i = \begin{cases} 1, & \text{с вероятност } p \text{ (успех)} \\ 0, & \text{с вероятност } q = 1 - p \text{ (неуспех)} \end{cases}$$

(Якоб Бернули (1654–1705), Швейцария)

Математическо очакване (средна стойност):

$$\mathbb{E}[X_i] = p, \text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = p - p^2 = p(1 - p) = pq$$

Дисперсия:

$\mathbb{E}[X^2] = 1^2 \cdot p + 0^2 \cdot (1 - p) = p$. Следователно:

$$\text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = p - p^2 = pq$$

Пораждаща функция (GPF):

$$G_X(s) = \mathbb{E}s^X = s^0q + s^1p = q + ps = 1 - p + ps$$

(Б) Биномно разпределение

Взимаме само първите n случайни величини от схемата на Бернули: X_1, X_2, \dots, X_n и образуваме сл. вел. $X = \sum_{i=1}^n X_i$, която ни отразява броя успехи измежду n експеримента.

Дефиниция (Биномно разпределение). Случайната величина X има биномно разпределение с параметри n (брой опити) и p (вероятност за успех във всеки опит), означаващо като:

$$X \sim \text{Binomial}(n, p) \equiv \text{Bin}(n, p),$$

ако представлява броя успехи в n независими опита на Бернули с вероятност за успех p .

Функция на масата на вероятностите (PMF: Probability Mass Function):

Комбинаторно избираме k експеримента от общо n , които да са успешни по $\binom{n}{k}$ начина и умножаваме по вероятността за успех p точно k пъти и $n - k$ пъти по вероятността за неуспех \Rightarrow

$$\mathbb{P}(X = k) = \binom{n}{k} p^k (1 - p)^{n-k}, k = 0, 1, 2, \dots, n$$

X	0	1	...	k	...	n
\mathbb{P}	q^n	npq^{n-1}	...	$\binom{n}{k} p^k q^{n-k}$...	p^n

k успеха измежду n експеримента всеки един измежду които се случва независимо от останалите с вероятност p за успех

Функция на разпределението (CDF: Cumulative Distribution Function):

$$F_X(k) = \mathbb{P}(X \leq k) = \sum_{i=0}^{\lfloor k \rfloor} \binom{n}{i} p^i (1-p)^{n-i}$$

Математическо очакване:

$$\mathbb{E}[X] = np$$

Доказателство:

$$\mathbb{E}[X] = \mathbb{E} \left[\sum_{i=1}^n X_i \right] = \sum_{i=1}^n \mathbb{E}[X_i] = \sum_{i=1}^n p = np,$$

където $X_i \sim \text{Bernoulli}(p)$ са независими.

Важно! Тук може да се забележи, че индексът на сумите започва от 1 а не от 0. Защо? Защото представяме X като сума от бернулиеви променливи: $X = X_1 + X_2 + \dots + X_n$. Тоест Тук индексът i минава по ОПИТИТЕ: 1, 2, ..., n .

Дисперсия:

$$\text{Var}[X] = np(1-p) = npq$$

Където $q = 1 - p$.

Доказателство:

$$\begin{aligned} \text{Var}[X] &= V \left[\sum_{i=1}^n X_i \right] = \sum_{i=1}^n \text{Var}[X_i] \quad (\text{от независимостта } \perp\!\!\!\perp) \\ &= \sum_{i=1}^n p(1-p) \quad \text{за } X_i \sim \text{Bernoulli}(p) \\ &= np(1-p) = npq \end{aligned}$$

Стандартно отклонение:

$$\sigma_X = \sqrt{np(1-p)} = \sqrt{npq}$$

Пораждаща функция (PGF):

$$G_X(s) = \mathbb{E}[s^X] = \sum_{k=0}^n s^k \binom{n}{k} p^k (1-p)^{n-k} = (1-p+ps)^n$$

Доказателство:

$$G_X(s) = \mathbb{E}[s^{\sum_{i=1}^n X_i}] = \prod_{i=1}^n \mathbb{E}[s^{X_i}] = \prod_{i=1}^n (1-p+ps) = (1-p+ps)^n.$$

Имайки пораждащата функция може да сведем проблема за извеждането на функцията на масата на вероятностите, математическото очакване и дисперсията до чисто аналитичен:

$$\begin{aligned}\mathbb{P}(X = k) &= \frac{G_X^{(k)}(0)}{k!} = \frac{\left((1 - p + ps)^n\right)^{(k)} \Big|_{s=0}}{k!} \\ &= \frac{\left(\sum_{k=0}^n \binom{n}{k} (ps)^k (1 - p)^{n-k}\right)^{(k)} \Big|_{s=0}}{k!} = \binom{n}{k} p^k (1 - p)^{n-k}\end{aligned}$$

$$\begin{aligned}G_X(s)' &= ((1 - p + ps)^n)' = n(1 - p + ps)^{n-1}(1 - p + ps)' \\ &= np(1 - p + ps)^{n-1}.\end{aligned}$$

$$\begin{aligned}G_X(s)'' &= (np(1 - p + ps)^{n-1})' = np(n - 1)(1 - p + ps)^{n-2}(1 - p + ps)' \\ &= n(n - 1)p^2s(1 - p + ps)^{n-2}.\end{aligned}$$

$$\mathbb{E}[X] = G_X'(1) = np(1 - p + ps)^{n-1} \Big|_{s=1} = np.$$

$$\text{Var}[X] = G_X''(1) + G_X'(1) - [G_X'(1)]^2 = n(n - 1)p^2 + np - n^2p^2 = np(1 - p).$$

⊕ Колко заразени биха влезли в България от чужбина, ако вероятността човек да е заразен е $p = 1\%$ и са се върнали $n = 100,000$ души. Тогава, не лош модел би бил следната случайна величина $X \sim \text{Bin}(n, p)$, която брой колко от върналите се в България са заразени. В случая неинтуитивно приемаме за успех вероятността човек да е заразен.

(В) Геометрично разпределение

При геометричното разпределение може да си мислим за последния пример, но по следния начин: Колко незаразени хора ще влязат в България, преди да влезе първия заразен, върнал се от чужбина?

Геометричното разпределение моделира броя на неуспехите преди първия успех (или броя на опитите до и включително първия успех) в поредица от независими опити на Бернули.

Има два основни варианта:

Вариант 1: Брой опити ДО първия успех (включително успеха)

$$X \sim \text{Geom}(p), \mathbb{P}(X = k) = (1 - p)^{k-1}p, k = 1, 2, 3, \dots$$

Тук X е броят опити до и включително първия успех.

Вариант 2: Брой неуспехи ПРЕДИ първия успех

$$Y \sim \text{Geom}(p), \mathbb{P}(Y = k) = (1 - p)^k p, k = 0, 1, 2, \dots$$

Тук Y е броят неуспехи преди първия успех.

Връзка: $Y = X - 1$, тоест $\mathbb{P}(Y = k) = \mathbb{P}(X = k + 1)$

Дефиниция (Геометрично разпределение).

$X \in \text{Geom}(p)$ и $X = \min \{k \geq 1 \mid \sum_{i=1}^k X_i = 1\}$. Тоест най-малкото k , за което сумата $\sum_{i=1}^k X_i$ става единица. Тъй като от тази сума НЕ вадим 1-ца, за да извадим последната стъпка (тази която носи събитието дефинирано като успех), то това е броя неуспехи до първи успех, включително успеха, тоест вариант 1.

$$\oplus \underbrace{0, 0, 0, \dots}_{\text{неуспехи}} \underbrace{1}_{\text{успех}} \Rightarrow X = 3; \oplus \underbrace{0, \dots}_{\text{неуспех}} \underbrace{1}_{\text{успех}} \Rightarrow X = 1; \oplus \underbrace{1}_{\text{успех}} \Rightarrow X = 0$$

Функция на вероятностите (PMF):

$$\mathbb{P}(X = k) = (1 - p)^k p, k = 0, 1, 2, \dots$$

X	0	1	2	...	k	...
\mathbb{P}	p	pq	pq^2	...	pq^k	...

k неуспеха преди първия успех

Функция на разпределението (CDF):

$$F_X(m) = \mathbb{P}(X \leq m) = 1 - (1 - p)^m$$

Доказателство:

$$\mathbb{P}(X \leq m) = \sum_{k=1}^m (1 - p)^{k-1} p$$

Това е крайна геометрична прогресия с:

- Първи член $a = p$
- Частно $r = 1 - p$
- Брой членове m

Сумираме:

$$\begin{aligned} F_X(m) &= p \cdot \frac{1 - (1 - p)^m}{1 - (1 - p)} \\ &= p \cdot \frac{1 - (1 - p)^m}{p} = 1 - (1 - p)^m, \quad m = 1, 2, 3, \dots \end{aligned}$$

За $m < 1$ очевидно $F_X(m) = 0$.

Математическо очакване:

$$\mathbb{E}[X] = \frac{1}{p}$$

Доказателство 1 (чрез сума):

$$\mathbb{E}[X] = \sum_{k=1}^{\infty} k(1-p)^{k-1}p$$

Използваме познат ред: $\sum_{k=1}^{\infty} kr^{k-1} = \frac{1}{(1-r)^2}$ за $|r| < 1$ (доказва се като вземем първата производна на геометричната прогресия $\sum_{k=0}^{\infty} r^k = \frac{1}{1-r}$ за $|r| < 1$).

Тук $r = 1 - p$, следователно

$$\mathbb{E}[X] = p \cdot \frac{1}{(1 - (1 - p))^2} = p \cdot \frac{1}{p^2} = \frac{1}{p}$$

Доказателство 2 (чрез безпаметност):

Нека $\mu = \mathbb{E}[X]$. При първи опит:

- С вероятност p имаме успех и броим 1 опит.
- С вероятност $1 - p$ имаме неуспех, изхарчили сме 1 опит, и поради безпаметността (паметта се нулира), очакваният брой допълнителни опити до успех отново е μ .

Следователно имаме уравнението:

$$\begin{aligned}\mu &= 1 \cdot p + (1 + \mu) \cdot (1 - p) \\ \mu &= p + (1 - p) + (1 - p)\mu = 1 + (1 - p)\mu \\ \mu - (1 - p)\mu &= 1 \Rightarrow p\mu = 1 \Rightarrow \mu = \frac{1}{p}\end{aligned}$$

Дисперсия:

$$\text{Var}[X] = \frac{1 - p}{p^2} = \frac{q}{p^2}$$

Доказателство (чрез момента от втори ред):

$$\mathbb{E}[X^2] = \sum_{k=1}^{\infty} k^2(1-p)^{k-1}p$$

Използваме познат ред: $\sum_{k=1}^{\infty} k^2 r^{k-1} = \frac{1+r}{(1-r)^3}$ (доказва се като вземем първата производна на геометричната прогресия $\sum_{k=0}^{\infty} r^k = \frac{1}{1-r}$ за $|r| < 1$).

Тук $r = 1 - p$:

$$\mathbb{E}[X^2] = p \cdot \frac{1 + (1-p)}{(1 - (1-p))^3} = p \cdot \frac{2-p}{p^3} = \frac{2-p}{p^2}.$$

$$\text{Var}[X] = \mathbb{E}[X^2] - (\mathbb{E}[X])^2 = \frac{2-p}{p^2} - \frac{1}{p^2} = \frac{1-p}{p^2} = \frac{q}{p^2}.$$

Стандартно отклонение:

$$\sigma_X = \sqrt{\text{Var}[X]} = \frac{q}{\sqrt{p}}$$

Пораждаща функция (PGF):

$$G_X(s) = \frac{ps}{1 - s(1-p)} = \frac{ps}{1 - qs}, \quad |s| < \frac{1}{1-p}$$

Доказателство:

$$\begin{aligned} G_X(x) &= \mathbb{E}[s^X] = \sum_{k=1}^{\infty} s^k \cdot \mathbb{P}(X = k) \\ &= \sum_{k=1}^{\infty} s^k \cdot q^{k-1} p = ps \sum_{k=1}^{\infty} (sq)^{k-1}. \end{aligned}$$

Забелязваме, че това е геометрична прогресия:

$$\sum_{k=1}^{\infty} (sq)^{k-1} = 1 + (sq) + (sq)^2 + \dots$$

Този ред е сходящ тогава и само тогава, когато $|sq| < 1$, тоест $|s| < \frac{1}{q}$.

От формулата за сума на безкрайна геометрична прогресия:

$$\sum_{k=1}^{\infty} (sq)^{k-1} = \frac{1}{1 - sq}, \quad |sq| < 1$$

Следователно:

$$G_X(s) = ps \cdot \frac{1}{q - sq} = \frac{ps}{1 - s(1-p)}, \quad |s| < \frac{1}{1-p}$$

Отново, имайки пораждащата функция може да сведем проблема за извеждането на математическото очакване и дисперсията до чисто аналитичен (само за тях, тъй като функцията $G_X(s)$ е сложна за намирането на k -та производна за функцията на масата на вероятностите):

$$\begin{aligned} G_X(s)' &= \left(\frac{ps}{1 - (1-p)s} \right)' = \frac{(ps)'(1 - (1-p)s) - ps(1 - (1-p)s)'}{(1 - (1-p)s)^2} \\ &= \frac{p(1 - s + ps) - ps(-1 + p)}{(1 - (1-p)s)^2} = \frac{p - \cancel{ps} + \cancel{p^2s} + \cancel{ps} - \cancel{p^2s}}{(1 - (1-p)s)^2} \\ &= \frac{p}{(1 - (1-p)s)^2}. \end{aligned}$$

$$\begin{aligned} G_X(s)'' &= \left(\frac{p}{(1 - (1-p)s)^2} \right)' = (p(1 - (1-p)s)^{-2})' \\ &= -2p(1 - (1-p)s)^{-3}(1 - (1-p)s)' = \\ &= \frac{2p(1-p)}{(1 - (1-p)s)^3}. \end{aligned}$$

$$\mathbb{E}[X] = G_X'(1) = \frac{p}{p^2} = \frac{1}{p}.$$

$$\begin{aligned} \text{Var}[X] &= G_X''(1) + G_X'(1) - [G_X'(1)]^2 = \frac{2p(1-p)}{p^3} + \frac{1}{p} - \frac{1}{p^2} = \\ &= \frac{2p - 2p^2 + p^2 - p}{p^3} = \frac{p(1-p)}{p^3} = \frac{1-p}{p^2} = \frac{q}{p^2}. \end{aligned}$$

По аналогичен начин може да докажем за Y :

$$G_Y(s) = \mathbb{E}[s^Y] = \frac{p}{1 - (1-p)s}, \quad |s| < \frac{1}{1-p}.$$

$$F_Y(m) = \mathbb{P}(Y \leq m) = 1 - (1-p)^{m+1}, \quad n = 0, 1, 2, \dots$$

$$\mathbb{E}[Y] = \frac{1-p}{p} = \frac{q}{p}.$$

$$\text{Var}[Y] = \text{Var}[X] \text{ и съответно } \sigma_Y = \sigma_X.$$

Връзка: $Y = X - 1$.

Внимание: Разликата е важна! Проверявай коя дефиниция се използва.

Свойство БЕЗПАМЕТНОСТ (Memoryless)

За всяко $m, n \geq 0$:

$$\mathbb{P}(X > m + n | X > m) = \mathbb{P}(X > n)$$

Интерпретация: Ако вече сме имали m неуспеха, разпределението на оставащите опити до успех е същото като в началото. Системата „не помни“ миналите неуспехи.

Доказателство:

$$\begin{aligned}\mathbb{P}(X > m + n | X > m) &= \frac{\mathbb{P}(X > m + n \text{ и } X > m)}{\mathbb{P}(X > m)} \\ &= \frac{\mathbb{P}(X > m + n)}{\mathbb{P}(X > m)} = \frac{1 - F_X(m + n)}{1 - F_X(m)} \\ &= \frac{(1 - p)^{m+n}}{(1 - p)^m} = (1 - p)^n = \mathbb{P}(X > n).\end{aligned}$$

Геометричното е единственото дискретно разпределение с това свойство!

⊕ (Вариант 1) Брой хвърляне на монета до първо „ези“: $X \sim \text{Geom}(p = 1/2)$.

⊕ (Вариант 2) Брой „тури“ при хвърляне на монета до първо „ези“: $Y \sim \text{Geom}(p = 1/2)$.

⊕ (Вариант 1) Брой хвърляния на зар до първата шестица: $X \sim \text{Geom}(p = 1/6)$.

⊕ (Вариант 2) Брой неуспешни атаки в баскетболен мач до първи кош. Ако грубо казано не се променят играчите и имат вероятност за успех, например 80 % за кош при атака, то броя на неуспешните атаки до първия успех може да се моделира добре като се допусне, че е разпределен геометрично с параметър $p = 0.8$. Тоест $Y \sim \text{Geom}(p = 4/5)$

(Г) Отрицателно биномно разпределение

Отрицателното биномно разпределение описва броя на опитите на Бернули, необходими за постигане на r успеха (където r е фиксирано цяло число).

Интуиция:

- При геометричното разпределение чакаме 1 успех
- При отрицателно биномното разпределение чакаме r успеха (обобщение)

Както при геометричното, така и тук имаме **два основни варианта**:

Вариант 1: Брой опити ДО r -тия успех (включително успеха)

$$X \sim \text{NBin}(p) \equiv \text{NB}(p), \mathbb{P}(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, k = r, r+1, r+2, \dots$$

Тук X е броят опити ДО първия успех (включително).

Интерпретация:

- Трябва точно r успеха и $k - r$ неуспеха

- Последният опит (k -тият) трябва да е успех
- Първите $k - 1$ опита трябва да имат точно $r - 1$ успеха
- Брой начини да подредим тези $r - 1$ успеха в $k - 1$ опита: $\binom{k-1}{r-1}$

Вариант 2: Брой неуспехи ПРЕДИ r -тия успех

$$Y \sim \text{NB}(p), \mathbb{P}(Y = k) = \binom{k+r-1}{r-1} p^r (1-p)^k$$

$$= \binom{n+r-1}{n} p^r (1-p)^n, \quad k = 0, 1, 2, \dots$$

Тук Y е броят неуспехи преди първия успех.

Връзка: $Y = X - r$, тоест $\mathbb{P}(Y = k) = \mathbb{P}(X = k + r)$

Специални случаи

Отрицателно биномно разпределение \rightarrow геометрично разпределение:

Когато $r = 1$:

$$\mathbb{P}(X = k) = \binom{k-1}{0} p^1 (1-p)^{k-1} = p(1-p)^{k-1}$$

Това е точно геометрично разпределение (вид 1).

Отрицателно биномно разпределение \rightarrow биномно разпределение:

За биномното: иуваме фиксиран брой опити n , броим успехите.

Тук имаме фиксиран брой успехи r , броим опитите.

Това са „двойноцо“ - едното е „огледалният образ“ на другото.

Дефиниция (Отрицателно биномно разпределение).

Отново ще разгледаме вариант 1:

$$X = \min \left\{ k \geq 1 \mid \sum_{i=1}^k X_i = r \right\}.$$

Тоест най-малкото k , за което сумата $\sum_{i=1}^k X_i$ става r . Тъй като от тази сума НЕ вадим 1-ца, за да извадим последната стъпка (тази която носи r -тото събитие дефинирано като успех), то това е броя на опитите до r -тия успех (включително).

$$\oplus \quad \underbrace{0, 0}_{\text{неуспехи}}, \quad \underbrace{1, 1}_{\text{успехи}}, \quad \underbrace{0, 0, 0, 0}_{\text{неуспехи}}, \quad \underbrace{1}_{\text{успех}} \Rightarrow X = 9, r = 3$$

$$\oplus \quad \underbrace{1, 1, 1, 1}_{\text{успехи}} \Rightarrow X = 4, r = 4$$

Функция на вероятностите (PMF):

$$\mathbb{P}(X = k) = \binom{k-1}{r-1} p^r (1-p)^{k-r}, k = r, r+1, r+2, \dots$$

X	0	1	...	k	...
\mathbb{P}	0	p	...	$\binom{k-1}{r-1} p^r (1-p)^{k-r}$...

k опита до
 r -тия успех (вкл.)

Функция на разпределението (CDF):

$$F_X(k) = \mathbb{P}(X \leq k) = \sum_{i=r}^k \mathbb{P}(X = i) = \sum_{i=r}^k \binom{i-1}{r-1} p^r (1-p)^{i-r},$$

$k \geq r$ (за $k < r$ вероятността е 0).

Ключова връзка с биномното разпределение:

$$F_X(k) = 1 - \sum_{i=0}^{r-1} \binom{k}{i} p^i (1-p)^{k-i}.$$

Доказателство:

Събитието $\{X \leq k\}$ означава, че сме постигнали r -тия успех най-късно на k -тия опит. Това е еквивалентно на: в първите k опита имаме поне r успеха.

Нека $B \sim \text{Binomial}(k, p)$ е броят успехи в k опита.

Тогава:

$$\begin{aligned} \mathbb{P}(X \leq k) &= \mathbb{P}(B \geq r) = 1 - \mathbb{P}(B \leq r-1) \\ &= 1 - \sum_{i=0}^{r-1} \binom{k}{i} p^i (1-p)^{k-i}. \end{aligned}$$

Пораждаща функция (PGF):

$$G_X(s) = \left(\frac{ps}{1-s(1-p)} \right)^r = \left(\frac{ps}{1-qs} \right)^r, |s| < \frac{1}{1-p}$$

Доказателство:

$$\begin{aligned} G_X(x) &= \mathbb{E}[s^X] = \sum_{k=r}^{\infty} s^k \cdot \mathbb{P}(X = k) \\ &= p^r \sum_{k=r}^{\infty} \binom{k-1}{r-1} (qs)^{k-r} \cdot s^r \end{aligned}$$

Правим смяна на индекса. Нека $j = k - r$, тогава $k = j + r$ и $j = 0, 1, 2, \dots$

$$G_X(s) = (ps)^r \sum_{j=0}^{\infty} \binom{j+r-1}{r-1} (qs)^j$$

Използваме биномен ред. Знаем, че за $|x| < 1$:

$$(1-x)^{-r} = \sum_{j=0}^{\infty} \binom{j+r-1}{r-1} x^j$$

Това е отрицателният биномен ред.

В нашия случай $x = qs$, така че:

$$\sum_{j=0}^{\infty} \binom{j+r-1}{r-1} (qs)^j = (1-qs)^{-r}, \quad |qs| < 1$$

Краен резултат

$$G_X(s) = (ps)^r \cdot (1-qs)^{-r} = \left(\frac{ps}{1-qs} \right)^r$$

Теорема (Отрицателното биомно разпределение като независими геометрични разпределени случайни величини).

Ако X_1, X_2, \dots, X_r са независими геометрично разпределени случайни величини с параметър p , то:

$$X_1 + X_2 + \dots + X_r \sim \text{NB}(r, p)$$

Интерпретация:

- X_1 = брой опити до 1-ви успех
- X_2 = брой опити до 2-ри успех (след първия)
- ...
- X_r = брой опити до r -ти успех (след $r-1$ -вия)
- Общо опити до r -тия успех: X_1, X_2, \dots, X_r

Доказателство чрез PGF:

PGF на геометрично (брой опити до успех):

$$G_{\text{geom}}(s) = \frac{ps}{1 - (1-p)s}$$

PGF на отрицателно биомно (брой опити до r успеха):

$$G_{nb}(s) = \left(\frac{ps}{1 - (1-p)s} \right)^r$$

Но това е точно r -та степен на PGF на геометричното!

$$G_{nb} = [G_{geom}(s)]^r$$

А PGF на сума от независими случайни величини е произведение на теха PGF-и.

Въпреки тази връзка, отрицателното биномно разпределение **НЯМА** свойството безпаметност (при $r > 1$), тъй като ако вече имаме някакъв брой успехи, това променя разпределението на оставащите опити.

Математическо очакване:

$$\mathbb{E}[X] = \frac{r}{p}$$

Доказателство 1 (чрез сума):

$$\mathbb{E}[X] = \sum_{k=r}^{\infty} k \cdot \binom{k-1}{r-1} p^r q^{k-r}$$

Използваме идентичността: $k \binom{k-1}{r-1} = r \binom{k}{r}$.

Доказателство на идентичността:

$$k \binom{k-1}{r-1} = k \cdot \frac{(k-1)!}{(r-1)!(k-r)!} = \frac{k!}{(r-1)!(k-r)!}$$

$$r \binom{k}{r} = r \cdot \frac{k!}{r!(k-r)!} = \frac{k!}{(r-1)!(k-r)!}$$

Тогава,

$$\mathbb{E}[X] = \sum_{k=r}^{\infty} r \binom{k}{r} p^r q^{k-r} = rp^2 \sum_{k=r}^{\infty} q^{k-r}.$$

Полагаме $m = k - r$ (тогава $k = m + r$, $m = 0, 1, 2, \dots$):

$$= rp^r \sum_{m=0}^{\infty} \binom{m+r}{r} q^m.$$

Използваме отрицателен биномен ред:

$$\sum_{m=0}^{\infty} \binom{m+r}{r} q^m = (1-q)^{-(r+1)}, \text{ за } |q| < 1$$

Но $(1-q) = p$, така че $(1-q)^{-(r+1)} = p^{-(r+1)}$. Тогава:

$$\mathbb{E}[X] = rp^r \cdot p^{-(r+1)} = rp^{-1} = \frac{r}{p}$$

Доказателство 2 (чрез сума от геометрични):

Знаем, че ако $X \sim \text{NB}(r, p)$, то X може да се представи като:

$$X = X_1 + X_2 + \dots + X_r$$

Където $X_i \sim \text{Geom}(p)$ са независими и всеки X_i е брой до първи успех. За геометрично разпределение знаем:

$$\mathbb{E}[X_i] = \frac{1}{p}$$

По линейност на очакването:

$$\mathbb{E}[X] = \mathbb{E}\left[\sum_{i=1}^r X_i\right] = \sum_{i=1}^r \mathbb{E}[X_i] = r \cdot \frac{1}{p} = \frac{r}{p}.$$

Доказателство 3 (чрез PGF):

PGF на X е:

$$G_X(s) = \left(\frac{ps}{1-qs}\right)^r$$

$$\begin{aligned} G'_X(s) &= r \left(\frac{ps}{1-qs}\right)^{r-1} \cdot \frac{d}{ds} \left(\frac{ps}{1-qs}\right) \\ &= r \left(\frac{ps}{1-qs}\right)^{r-1} \cdot \frac{p(1-qs) - ps(-q)}{(1-qs)^2} = \\ &= r \left(\frac{ps}{1-qs}\right)^{r-1} \cdot \frac{p - pqs + pqs}{(1-qs)^2} = r \left(\frac{ps}{1-qs}\right)^{r-1} \cdot \frac{p}{(1-qs)^2} \end{aligned}$$

При $s = 1$:

$$G'_X(1) = r \left(\frac{p}{1-q}\right) \cdot \left(\frac{p}{(1-q)^2}\right) = r \left(\frac{p}{p}\right)^{r-1} \cdot \frac{p}{p^2} = r \cdot 1 \cdot \frac{1}{p} = \frac{r}{p}$$

Аналогично се доказва, че за Вариант 2: $\mathbb{E}[X] = \frac{r(1-p)}{p} = \frac{rq}{p}$.

Дисперсия:

$$\text{Var}[X] = \frac{1-p}{p^2} = \frac{q}{p^2}$$

Доказателство:

Ще го направим само по елегантния начин чрез сума от геометрично разпределени случайни величини.

$$\text{Var}[X] = \text{Var} \left[\sum_{i=1}^r Y_i \right] \stackrel{\text{незав.}}{\equiv} \sum_{i=1}^r \text{Var}[Y_i] = r \cdot \frac{q}{p^2} = \frac{rq}{p^2} = \frac{r(1-p)}{p^2}.$$

Стандартно отклонение:

$$\sigma_X = \sqrt{\text{Var}[X]} = \frac{\sqrt{r(1-p)}}{p} = \frac{\sqrt{rq}}{p}.$$

Аналичичен подход за извеждане на PMF чрез PGF:

Знаем, че:

$$G_X(s) = \left(\frac{ps}{1-qs} \right)^r, \quad q = 1-p, \quad |s| < \frac{1}{q}$$

където $X = r, r+1, r+2, \dots$

Развиваме $G_X(s)$ в ред на Тейлър около $s = 0$.

Първо развиваме $(1-qs)^{-r}$ с отрицателен биномен ред:

$$(1-qs)^{-r} = \sum_{n=0}^{\infty} \binom{n+r-1}{r-1} (qs)^n$$

за $|qs| < 1$.

Тогава:

$$G_X(s) = p^r s^r \sum_{n=0}^{\infty} \binom{n+r-1}{r-1} q^n s^n = p^r \sum_{n=0}^{\infty} \binom{n+r-1}{r-1} q^n s^{n+r}$$

Правим смяна на индекса $k = n+r$, тогава $n = k-r$ и $k = r, r+1, r+2, \dots$

$$\begin{aligned}
 G_X(s) &= \sum_{k=r}^{\infty} p^r \binom{(k-r)+r-1}{r-1} q^{k-r} \\
 &= \sum_{k=r}^{\infty} p^r \binom{k-1}{r-1} q^{k-r} s^k.
 \end{aligned}$$

Тъй като $G_X(s) = \sum_{k=r}^{\infty} \mathbb{P}(X = k) s^k$, сравняваме коефициентите:

$$\mathbb{P}(X = k) = p^r \binom{k-1}{r-1} q^{k-r}, \quad k = r, r+1, r+2, \dots$$

(Д) Поасоново разпределение

Поасоновото разпределение моделира броя на събития, случващи се в фиксиран интервал от време или пространство, при следните условия:

- Събитията се случват независимо
- Средният брой събития в интервала е постоянен (обозначава се с λ)
- Две събития не могат да се случват точно в един и същи момент
- Вероятността за събитие в много малък интервал е пропорционална на дължината на интервала

Дефиниция (Поасоново разпределение). Нека $\lambda > 0$. Казваме, че X е поасоново разпределена случайна величина с параметър λ и бележим с $X \sim \text{Pois}(\lambda)$, ако:

$$\mathbb{P}(X = k) = \frac{\lambda^k}{k!} e^{-\lambda}, \quad k \geq 0$$

Проверка (за това дали функцията може да е вероятност):

$$1 \stackrel{?}{=} \sum_{k=0}^{\infty} \mathbb{P}(X = k) = \sum_{k=0}^{\infty} \frac{\lambda^k}{k!} e^{-\lambda} = e^{-\lambda} \cdot \underbrace{\sum_{k=0}^{\infty} \frac{\lambda^k}{k!}}_{\text{развитие в ред на Тейлър за } e^{\lambda}} = e^{-\lambda} \cdot e^{\lambda} = 1$$

Какво може да се моделира добре с поасоново разпределена случайна величина:

- ⊕ Брой постъпили заявки към сървър за единица време
- ⊕ Брой катастрофи за единица време на дадено кръстовище или територия
- ⊕ Брой насекоми за единица площ
- ⊕ Брой глави за единица време
- ⊕ Брой звезди в някакъв регион
- ⊕ Брой получени обаждания в кол център на час

Пораждаща функция (PGF):

$$\begin{aligned} G_X(s) &= \mathbb{E}[s^X] = \sum_{k=0}^{\infty} s^k \cdot \mathbb{P}(X = k) = \sum_{k=0}^{\infty} s^k \cdot \frac{\lambda^k e^{-\lambda}}{k!} \\ &= e^{-\lambda} \sum_{k=0}^{\infty} \frac{(\lambda s)^k}{k!} = e^{-\lambda} \cdot e^{\lambda s} = e^{\lambda(s-1)}. \end{aligned}$$

$$G'_X(x) = (e^{\lambda(s-1)})' = (\lambda(s-1))' e^{\lambda(s-1)} = \lambda e^{\lambda(s-1)}$$

$$G''_X(x) = (\lambda e^{\lambda(s-1)})' = (\lambda(s-1))' \lambda e^{\lambda(s-1)} = \lambda^2 e^{\lambda(s-1)}$$

Математическо очакване:

$$\mathbb{E}[X] = \lambda$$

Доказателство:

$$\mathbb{E}[X] = G'_X(1) = \lambda e^{\lambda(1-1)} = \lambda e^0 = \lambda.$$

Дисперсия:

$$\text{Var}[X] = \lambda$$

Доказателство:

$$\text{Var}[X] = G''_X(1) + G'_X(1) - [G_X(1)]^2 = \lambda^2 + \lambda - \lambda^2 = \lambda.$$

Теорема (Симеон Дени Поасон (1781–1840), Франция).

Нека $X_n \sim \text{Bin}(n, p_n)$, където вероятността за успех p_n зависи от n .

Ако $n \rightarrow \infty$ и $p_n \rightarrow 0$ така, че $np_n \rightarrow \lambda > 0$, тогава за всяко фиксирано $k = 0, 1, 2, \dots$:

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = \frac{\lambda^k e^{-\lambda}}{k!}$$

Тоест, биномното разпределение се доближава до поасоново с параметър λ .

Интуиция

Когато имаме:

- Много опити (n е голямо)
- Много рядък успех (p е много малко)
- Но средният брой успехи np остава постоянен ($\approx \lambda$)

Тогава биномното разпределение става неразлично от поасоновото

Това на практика означава, че с поасоновото разпределение може много добре да приближаваме биномното разпределение, когато имаме много на брой опити.

Доказателство:

За $X_n \sim \text{Bin}(n, p_n)$:

$$\mathbb{P}(X_n = k) = \binom{n}{k} p_n^k (1 - p_n)^{n-k} = \frac{n(n-1)\cdots(n-k+1)}{k!} \cdot p_n^k \cdot (1 - p_n)^{n-k}$$

Нека $\lambda_n = np_n$. По условие $\lambda_n \rightarrow \lambda$ при $n \rightarrow \infty$. Тогава $p_n = \frac{\lambda_n}{n}$. Заместваме:

$$\begin{aligned} \mathbb{P}(X_n = k) &= \frac{n(n-1)\cdots(n-k+1)}{k!} \cdot \left(\frac{\lambda_n}{n}\right)^k \cdot \left(1 - \frac{\lambda_n}{n}\right)^{n-k} \\ &= \frac{n(n-1)\cdots(n-k+1)}{n^k} \cdot \frac{\lambda_n^k}{k!} \cdot \left(1 - \frac{\lambda_n}{n}\right)^{n-k} \\ &= 1 \cdot \left(1 - \frac{1}{n}\right) \cdot \left(1 - \frac{2}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right) \cdot \frac{\lambda_n^k}{k!} \cdot \left(1 - \frac{\lambda_n}{n}\right)^{n-k}. \end{aligned}$$

Граничен преход $n \rightarrow \infty$:

Първата част от множителите:

$$\lim_{n \rightarrow \infty} \left(1 - \frac{1}{n}\right) \cdot \left(1 - \frac{2}{n}\right) \cdots \left(1 - \frac{k-1}{n}\right) = 1$$

Втората част от множителите:

$$\frac{\lambda_n^k}{k!} \rightarrow \frac{\lambda^k}{k!} \text{ (тъй като } \lambda_n \rightarrow \lambda)$$

Третата част от множителите:

$$\left(1 - \frac{\lambda_n}{n}\right)^{n-k} = \left(1 - \frac{\lambda_n}{n}\right)^n \cdot \left(1 - \frac{\lambda_n}{n}\right)^{-k}$$

Знаем, че:

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\lambda_n}{n}\right)^n = e^{-\lambda} \text{ (тъй като } \lambda_n \rightarrow \lambda)$$

$$\lim_{n \rightarrow \infty} \left(1 - \frac{\lambda_n}{n}\right)^{-k} = 1$$

Следователно, комбинирайки резултатите, получаваме:

$$\lim_{n \rightarrow \infty} \mathbb{P}(X_n = k) = 1 \cdot \frac{\lambda^k}{k!} \cdot e^{-\lambda} \cdot 1 = \frac{\lambda^k e^{-\lambda}}{k!}$$

Това е точно PMF на поасоновото разпределение!

⊕ $p = 0.01$ вероятност даден човек да е заразен с вирус и $n = 1,000$.

$$\mathbb{P}(X = 50) = \binom{1,000}{50} \times 0.01^{50} \times 0.99^{950} \stackrel[\lambda=np=10]{\text{Pois}} \frac{10^{50}}{50!} e^{-10}$$

$$\mathbb{P}(X = 0) \approx \frac{10^0}{0!} e^{-10} = e^{-10}.$$

Практическо правило

Правило на пръста: Може да използваме поасоново приближение за биномно разпределение, когато:

$$n \geq 20 \text{ и } p \leq 0.05$$

Или по-точно:

$$n \geq 100 \text{ и } np \leq 10$$

⊕ Ситуация: Фабрика произвежда чипове с дефектност 0.5%. В партида от 1000 чипа, каква е вероятността да има точно 3 дефектни?

Точен биномен модел:

$$n = 1000, p = 0.005, k = 3$$

$$\mathbb{P}(X = 3) = \binom{1000}{3} (0.005)^3 (0.995)^{997}$$

Това трудно се изчислява на ръка.

Поасоново приближение:

$$\lambda = np = 1000 \times 0.005 = 5$$

$$\mathbb{P}(X = 3) \approx \frac{5^3 e^{-5}}{3!} = \frac{125 \times e^{-5}}{6} \approx \frac{125 \times 0.0067379}{6} \approx 0.1404$$

Реалната биномна вероятност е приблизително 0.1404.

Аналитично доказателство на теоремата чрез PGF:

Нека $X_n \in \text{Bin}(n, p_n)$, тогава $g_{X_n} = (1 - p_n + p_n s)^n$. Ако $g_{X_n}(s) \xrightarrow{n \rightarrow \infty} g_X(s)$, където $g_X(s) = e^{\lambda s} \cdot e^{-\lambda}$, то може да заключим искания резултат, тъй като $e^{\lambda s} \cdot e^{-\lambda}$ е пораждаща функция на $X \in \text{Pois}(\lambda)$.

Може да вземем $p_n = \frac{\lambda}{n} + \frac{Q_n}{n}$, като $\frac{Q_n}{n}$ клони по-бързо от $\frac{\lambda}{n}$ към 0. Тогава:

$$\lim_{n \rightarrow \infty} g_{X_n}(s) = \lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n} - \underbrace{\frac{Q_n}{n}}_{< O\left(\frac{1}{n}\right)} + \frac{\lambda}{n}s + \frac{Q_n}{n}s \right)^n = \lim_{n \rightarrow \infty} \left(1 - \frac{\lambda}{n}(1 - s) \right)^n = e^{\lambda(s-1)}.$$