

Доверителни интервали

Постановка.

- Случайна величина X
- $F_X(x, \theta)$ е разпределение, което искаме да разберем, като знаем че то зависи параметрично от някакъв параметър θ
- $\theta = (\theta_1, \dots, \theta_s)$ са s на брой параметри (например при нормалното разпределение са $s = 2$: средно μ и стандартно отклонение σ)

$\vec{X}(X_1, \dots, X_n)$ е вектор от n независими еднакво разпределени наблюдения над X (прототипи на X). На база на тези наблюдения, които в крайна сметка ще бъдат сведени до някакви числа (за модела/за експеримента) трябва да намерим някаква оценка $\hat{\theta} = \hat{\theta}(\vec{X})$, която да я вземем близо до θ , така че да определи това
 $\underbrace{\hat{\theta} = \hat{\theta}(\vec{X})}_{\text{точкова оценка}}$
 разпределение $F_X(x, \theta)$.

Проблемът с точковата оценка е, че тя варира в зависимост от конкретната извадка. Това е очаквано, тъй като различните извадки дават различни резултати. Затова, освен точечната оценка $\hat{\theta}$, би било много по-информативно да разполагаме с интервал от стойности, в който с дадена вероятност се намира истинският параметър θ . Такъв интервал се нарича *доверителен интервал*.

Ще разглеждаме само едномерни параметри θ ($\theta \in \mathbb{R}$).

Цел. Ще търсим две числа L и U , такива, че:

$$\mathbb{P}(L \leq \theta \leq U) = 1 - \alpha,$$

където α обикновено е число между 0 и 1 ($0 < \alpha < 1$) и има следния смисъл: колкото по-малко е α , толкова по-широки интервали ще се получават, за да може с по-голяма вероятност (повече „сигурност“) да покрием истинския параметър θ . Стандартно, $\alpha = 0.05$ (което отговаря на 95% доверителен интервал). Стойност като $\alpha = 0.10$ се използва за по-маловажни изследвания или предварителни анализи, докато за медицински или много критични цели може да се използва $\alpha = 0.01$.

Дефиниция (Централна статистика ЦС). Казваме, че $T = T(\vec{X}, \theta)$ е централна статистика, ако:

- 1) T е монотонна по θ
- 2) $\mathbb{P}(T < x) = F_T(x)$ не зависи от θ (T е функция на θ , но разпределението и не зависи от θ)

⊕ Имаме \vec{X} (вектор от наблюдения) и искаме да намерим някакъв доверителен интервал: (L, U) за θ , тоест $\theta \in (L, U)$. Целта ни е да имаме някакво ниво на доверие $1 - \alpha = \mathbb{P}(q_1 < T < q_2)$. За улеснение ще допуснем, че T расте по θ (но тя може и да намалява по θ).


Тъй като T е монотонна по θ , то:

$$1 - \alpha = \mathbb{P}(q_1 < T < q_2) \quad \begin{array}{l} \text{при фиксиран} \\ \text{вектор на} \\ \text{наблюдения } \vec{X} \end{array} = \mathbb{P}(T^{-1}(q_1) < \theta < T^{-1}(q_2)),$$

тъй като сме допуснали, че T расте по θ . Ако T намаляваше по θ , щяхме да имаме $1 - \alpha = \mathbb{P}(T^{-1}(q_2) < \theta < T^{-1}(q_1))$. Следователно интервалът ще е:

$$L = T^{-1}(q_1), U = T^{-1}(q_2).$$

f_T - плътността на централната статистика (ЦС)




Има много начини, по които може да изберем q_1 и q_2 , така че вероятността между тях да е $1 - \alpha$.

Имаме параметър $\theta \in \mathbb{R}$, който искаме да оценим. Търсим L и U , които да зависят от наблюденията \vec{X} и $L(\vec{X}) < U(\vec{X})$. Те образуват така наречения *доверителен интервал* за θ с ниво на доверие $1 - \alpha = \mathbb{P}(\theta \in (L, U))$.

T е централна статистика за θ , ако удовлетворява дефиницията за ЦС.


⊕ Ако T е симетрична случайна величина,



тогава се търсят такива q_1 и q_2 , че $q_1 = -q = -q_2$, за които

$$\mathbb{P}(T < -q) = 1 - \mathbb{P}(T < q) = \frac{\alpha}{2} \text{ (за да имаме по средата вероятност } 1 - \alpha)$$

По-общо, ако имаме някакво несиметрично разпределение на T :



$$\text{проверка : } \mathbb{P}(T < q_2) - \mathbb{P}(T < q_1) = \frac{\alpha}{2} + 1 - \alpha - \frac{\alpha}{2} = 1 - \alpha$$

Има много възможни начини за избор на границите q_1 и q_2 на доверителния интервал. Въпреки това, формулите, представени по-горе, не са произволни. Те са стандартизирани и добре установени методи в статистическата практика, които произлизат директно от свойствата на пивотните величини.

$$\underbrace{1 - \alpha}_{\text{фиксирана}} = \mathbb{P}(q_1 < T < q_2) = \mathbb{P}\left(\underbrace{T^{-1}(q_1) < \theta < T^{-1}(q_2)}_{T \text{ нарастваща}}\right).$$

Тази вероятност $1 - \alpha$ е фиксирана и се задава предварително от изследователите. Какво може да оптимизираме ние като математици? Може да търсим q_1 и q_2 такива, за които е изпълнено:

$$\min_{\substack{q_1 < q_2 \\ 1 - \alpha = \mathbb{P}(q_1 < T < q_2)}} = \left\{ \underbrace{\left| T^{-1}(q_2) - T^{-1}(q_1) \right|}_{\substack{\text{искаме интервал с минимална} \\ \text{дължина, за да ограничим} \\ \text{възможните стойности на} \\ \text{параметъра } \theta \text{ максимално}}} \right\}.$$

Тоест минимизираме доверителния интервал при фиксирано ниво на доверие!

$$\oplus \quad \underbrace{X \in \mathcal{N}(\mu, \sigma^2)}_{\substack{\text{случайна величина, която} \\ \text{искаме да изучаваме}}}, \sigma^2 \text{ е известно,}$$

тоест интересуваме се само от параметъра $\mu = \theta$ (едномерен). Искаме да видим как може да оценим μ и да намерим за него доверителен интервал.

Ние знаем, че $\hat{\mu} = \bar{X}_n = \frac{1}{n} \sum_{i=1}^n X_i$. Тогава $T(\vec{X}, \mu) = \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \sim \mathcal{N}(0,1)$, σ е известно

число. Това е така, защото:

$$\sum_{i=1}^n X_i \overset{\substack{\text{линейност} \\ \text{на } \mathcal{N} \text{ и незав.}}}{\sim} \mathcal{N}(n\mu, n\sigma^2) \Rightarrow \frac{1}{n} \sum_{i=1}^n X_i \sim \mathcal{N}\left(\frac{n\mu}{n}, \frac{n\sigma^2}{n^2}\right) = \mathcal{N}\left(\mu, \frac{\sigma^2}{n}\right).$$


По-подробно обяснение на свойството линейност на нормалното разпределение:

$$\bar{X}_n = \frac{\sum_{i=1}^n X_i}{n} \sim \mathcal{N}(x, y^2); \mathbb{E}\bar{X}_n = \frac{n\mu}{n} = x; \text{Var}[\bar{X}_n] = \frac{1}{n^2} \sum_{i=1}^n \sigma^2 = \frac{\sigma^2}{n} = y^2$$

T е намаляваща функция по μ и $\mathbb{P}(T \leq x) = \frac{1}{\sqrt{2\pi}} \int_{-\infty}^x e^{-\frac{y^2}{2}} dy$ - не зависи от $\mu \stackrel{\text{def.}}{\Rightarrow}$

T е централна статистика за μ (тя е монотонна и намаляваща по μ и нейното разпределение съвпада с $\mathcal{N}(0,1)$, тоест не зависи от θ)

Тогава, $1 - \alpha = \mathbb{P}(-q < T < q)$, тъй като $\mathcal{N}(0,1)$ е симетрично:



Това ни гарантира, че $(-q, q)$ ще е най-късия интервал, тъй като в $(-\infty, -q)$ и (q, ∞) е сбита най-малко маса (навсякъде извън тези интервали е сбита повече маса)

$q = q_{\frac{1}{2} + \frac{1-\alpha}{2}}$, който квантил го има в таблицата за нормалното стандартно разпределение.

$$\begin{aligned}
1 - \alpha &= \mathbb{P}(-q < T < q) = \mathbb{P}\left(-q_{\frac{1}{2} + \frac{1-\alpha}{2}} < \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} < q_{\frac{1}{2} + \frac{1-\alpha}{2}}\right) \Rightarrow \\
&\Rightarrow \mathbb{P}\left(\mu \in \underbrace{\left(\bar{X}_n - \frac{\sigma}{\sqrt{n}} \cdot q_{\frac{1}{2} + \frac{1-\alpha}{2}}, \bar{X}_n + \frac{\sigma}{\sqrt{n}} \cdot q_{\frac{1}{2} + \frac{1-\alpha}{2}}\right)}_L\right) = 1 - \alpha \Rightarrow \\
&\Rightarrow L = \bar{X}_n - \frac{\sigma}{\sqrt{n}} \cdot q_{\frac{1}{2} + \frac{1-\alpha}{2}}; \quad U = \bar{X}_n + \frac{\sigma}{\sqrt{n}} \cdot q_{\frac{1}{2} + \frac{1-\alpha}{2}}
\end{aligned}$$

$\oplus X \sim \mathcal{N}(\mu, \sigma^2)$, но този път не знаем σ .

Как да конструираме доверителен интервал само за μ ? Припомняме, че

$\hat{\mu} = \bar{X}_n$ и оценката за дисперсията е $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X}_n)^2$ и е неизместена.
 независимо
 дали знаем
 или не σ

Фактора $\frac{1}{n-1}$ го има, тъй като тя е неизместена оценка за дисперсията.

Твърдение. Имаме, че $X \sim \mathcal{N}(\mu, \sigma^2)$ и $\vec{X} = (X_1, \dots, X_n)$ са наблюдения над X .
 Тогава е вярно, че:

- $\hat{\mu}$ е независимо от s^2 : $\hat{\mu} \perp s^2$
- $(n-1) \frac{s^2}{\sigma^2} \sim \mathcal{X}^2(n-1)$.

$T = \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}}$. Ако знаехме σ , последното щеше да е разпределено като $\mathcal{N}(0,1)$
 неизвестно

(както направихме в предходния пример), но ние не знаем σ . Но друго, което знаем е, че:

$$T = \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} = \frac{\frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}}}{\sqrt{\frac{n-1}{n-1} \cdot \frac{s^2}{\sigma^2}}} = \frac{\bar{X}_n - \mu}{\frac{s}{\sqrt{n}}} \text{ е централна статистика!}$$

$\sim \mathcal{N}(0,1)$
 $\sim \mathcal{X}^2(n-1)$


Тъй като $\frac{\bar{X}_n - \mu}{\frac{s}{\sqrt{n}}} = \frac{Z}{\sqrt{\frac{Y}{n-1}}}$, където $Z \sim \mathcal{N}(0,1)$, $Y \sim \mathcal{X}^2(n-1)$ и $Z \perp Y$.

Заклучения.

- T е намаляваща по μ
- $T \in t(n-1)$ и не зависи от $\mu \Rightarrow T$ е централна статистика за μ .

$$T = \frac{Z}{\sqrt{\frac{Y}{n-1}}}; \quad Z = \frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}}; \quad Y = \frac{(n-1)s^2}{\sigma^2}.$$

T е симетрична, тъй като в числителя имаме симетрична случайна величина (Z) \Rightarrow



$$\Rightarrow \mathbb{P} \left(-q_{\frac{1}{2} + \frac{1-\alpha}{2}} < T < q_{\frac{1}{2} + \frac{1-\alpha}{2}} \right) = \mathbb{P} \left(\mu \in \left(\bar{X}_n - q_{\frac{1}{2} + \frac{1-\alpha}{2}} \cdot \frac{s}{\sqrt{n}}, \bar{X}_n + q_{\frac{1}{2} + \frac{1-\alpha}{2}} \cdot \frac{s}{\sqrt{n}} \right) \right)$$

тоест имаме, че L и U зависят от s и квантилите не са от нормалното разпределение а от t – Student's разпределението.

Бележки. $T = \frac{\bar{X}_n - \mu}{\frac{s}{\sqrt{n}}} = \frac{Z}{\sqrt{\frac{Y}{n-1}}}, Z \perp Y, Z \sim \mathcal{N}(0,1), Y \sim \mathcal{X}^2(n-1)$

- $Y = \sum_{j=1}^{n-1} V_j$, където $\{V_i\}_{i=1}^{n-1}$ са независими и еднакво разпределени (i.i.d.) с $\mathcal{X}^2(1)$.

От ЗГЧ: $\frac{Y}{n-1} \xrightarrow[n \rightarrow \infty]{\text{п.с.}} \mathbb{E}[V_1] = 1$. Следователно за големи n : $T \approx \frac{Z}{1} \approx \mathcal{N}(0,1)$;

- Ако знаем дисперсията: $\frac{\bar{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \xrightarrow[n \rightarrow \infty]{d} \mathcal{N}(0,1)$ за произволни X_1, \dots, X_n, \dots

$$\mathbb{E}[X_1] = \mu; \quad \text{Var}[X_1] = \sigma^2.$$


$\oplus X \sim \mathcal{N}(\mu, \sigma^2)$, знаем μ , $\hat{\sigma}^2 = \frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2$. Искаме да оценим дисперсията.

Трябва да конструираме централна статистика. ЦС не трябва да зависи от σ , но в $\hat{\sigma}^2$, X_j зависи от σ и трябва да отстраним тази зависимост.

Нагаждаме: $\frac{n\hat{\sigma}^2}{\sigma^2} = \sum_{i=1}^n \underbrace{\left(\frac{X_i - \mu}{\sigma}\right)^2}_{Z_i^2} = \sum_{i=1}^n Z_i^2$, но $Z_i \sim \mathcal{N}(0,1)$, тъй като центрираме и

нормираме с неизвестна дисперсия. Следователно $\sum_{i=1}^n Z_i^2 \sim \mathcal{X}^2(n)$, защото сумира n квадрати на независими нормални стандартно разпределени $Z \Rightarrow$ статистиката $T = \frac{n\hat{\sigma}^2}{\sigma^2}$ е централна по дефиниция (разпределението и е $\mathcal{X}^2(n)$ – не зависи от σ^2 и тя е монотонно намаляваща по σ).

За квантилите:




$$1 - \alpha = \mathbb{P}(q_1 < T < q_2) = \mathbb{P}\left(\frac{n\hat{\sigma}^2}{q_2} < \frac{n\hat{\sigma}^2}{q_1}\right) \Rightarrow \begin{cases} L = \frac{n\hat{\sigma}^2}{q_2} \\ U = \frac{n\hat{\sigma}^2}{q_1} \end{cases}$$

$\oplus X \sim \mathcal{N}(\mu, \sigma^2)$, не знаем μ и се интересуваме от σ^2 . Знаем, че s^2 е неизместена оценка за σ^2 :

$(n-1)s^2 = \sum_{i=1}^n (X_i - \bar{X}_n)^2$ и нашата цел е да конструираме статистика за σ^2 , тоест да намерим ЦС, отговаряща на дефиницията. Ако разделим на σ^2 , от дясно не можем да направим никакво заключение: $\frac{(n-1)s^2}{\sigma^2} = \frac{\sum_{i=1}^n (X_i - \bar{X}_n)^2}{\sigma^2}$, но знаем от твърдението, че $T = \frac{(n-1)s^2}{\sigma^2} \sim \mathcal{X}^2(n-1)$ (с една степен по-малко, защото сме изхабили една степен за оценката на μ). От n наблюдения все едно имаме $n-1$ наблюдения.

$\Rightarrow T$ е централна статистика (монотонна намаляваща по σ^2 и независима от σ^2)



$$1 - \alpha = \mathbb{P} \left(q_1 < \frac{(n-1)s^2}{\sigma^2} < q_2 \right) = \mathbb{P} \left(\frac{(n-1)s^2}{q_2} < \sigma^2 < \frac{(n-1)s^2}{q_1} \right)$$

$$L = \frac{1}{q_2}(n-1)s^2; \quad U = \frac{1}{q_1}(n-1)s^2$$

При голямо n ($n > 30$ например) може да ползваме както от предходния пример - все едно знаем σ .

Проверка на хипотези

Теорията за проверка на хипотези не е откритие на един човек, а се развива през 20-ти век чрез приносите на няколко ключови статистици. В основата на съвременната теория стоят Роналд Фишър (1890 – 1962, Великобритания), който въвежда основите, и Йерзи Сплава-Нейман (1894 – 1981, Поляк) с Егон Шарп Пирсън (1895 – 1980, Великобритания), които я формализират. В по-ранни времена зачатъците на идеите могат да се открият дори в работите на Джон Арбътнот през 18-ти век. Тя най-често се задава със следната математическа постановка:

X е случайна величина с функция на разпределение $F_X(x, \theta)$, нулева хипотеза H_0 и алтернативна такава H_1 , където θ е оценяваният параметър.

- $H_0 : \theta = \theta_0$
- $H_1 : \theta = \theta_1$

Искаме да конструираме някакво множество $W \in \mathbb{R}^n$ такова, че ако \vec{X} попадне в W ($\vec{X} \in W$), тогава отхвърляме H_0 (в полза на H_1). Ако векторът от наблюдения \vec{X} не попадне в W , то тогава не отхвърляме H_0 .

H_0 и H_1 се наричат прости хипотези (нулева и алтернативна). Прости хипотези са $\theta = \theta_1$ (число). Сложни хипотези са $\theta > \theta_i$, $\theta \neq \theta_i$, $\theta \in I$ и т.н.

Цел. При наблюденията $\vec{X} \in \mathbb{R}^n$, търсим да конструираме $W \subseteq \mathbb{R}^n$: ако $\vec{X} \in W$, то отхвърляме H_0 и приемаме H_1 , а ако $\vec{X} \in \bar{W}$, то приемаме H_0 .

$$W \subseteq \mathbb{R}^n : \begin{cases} \vec{X} \in W \Rightarrow \text{отхвърляме } H_0 \\ \vec{X} \in \bar{W} \Rightarrow \text{приемаме } H_0 \end{cases}$$

Грешки, които може да допуснем:

- Грешка от I^{-ви} род: Да отхвърлим H_0 , когато H_0 е вярна, тоест:

$$\alpha = \mathbb{P}(\vec{X} \in W | H_0)$$

- Грешка от II^{-ви} род: При положение, че е вярна хипотезата H_1 , ние сме приели H_0 , тоест

$$\beta = \mathbb{P}(\vec{X} \in \bar{W} | H_1)$$

$$\pi = 1 - \beta \text{ се нарича мощност на } W$$

$\oplus H_0$: дадена ваксина е вредна ($\theta = \theta_0$). H_1 : ваксината не е вредна ($\theta = \theta_1$)

Има по-голям резон за H_0 да вземем по-опасната/рисковата хипотеза. Това е тази хипотеза, която е по-вероятно да я отхвърлим. Това е така, защото грешката от I^{-ви} род ще бъде контролирана/задавана от изследователя (той ще казва дали иска/допуска да е 0.01, 0.05, 0.10 и т.н.)

Дефиниция (Оптимална критична област). При фиксирана грешка от I^{-ви} род α , $W^* \subseteq \mathbb{R}^n$ се нарича оптимална критична област (ОКО), ако

$$\mathbb{P}(\vec{X} \notin W^* | H_1) = \min_{\substack{W \subseteq \mathbb{R}^n \\ \text{всички критични области} \\ \alpha = \mathbb{P}(X \in W | H_0)}} \mathbb{P}(\vec{X} \notin W | H_1).$$

Постановка. X е случайна величина; $F_X(x, \theta)$ е разпределението на X , което зависи от някакъв параметър θ , но допускаме, че $f_X(x, \theta)$ е плътността на X (тоест допускаме, че $\frac{\partial}{\partial x} F_X(x, \theta)$ съществува). Въвеждаме:

$$f_{\vec{X}}(x, \theta) = \underbrace{L(X, \theta)}_{\text{функция на правдоподобие}} = \prod_{i=1}^n f_X(x_i, \theta), \text{ където } x \in \mathbb{R}^n \text{ и } x = (x_1, \dots, x_n).$$

Тогава е верен следния резултат:

Лема (Нейман-Пирсън). Нека X удовлетворява горните условия от постановката и нека тестваме следната хипотеза:


$$H_0 : \theta = \theta_0 \text{ срещу } H_1 : \theta = \theta_1.$$

Ако $L_0(x) = L(x, \theta_0)$ и $L_1(x) = L(x, \theta_1)$ и

$\exists k \geq 0 : W^* \subseteq \{x \in \mathbb{R}^n : L_1(x) \geq kL_0(x)\}$, $\bar{W}^* \subseteq \{X \in \mathbb{R}^2 : L_1(x) \leq kL_0(x)\}$ и $\alpha = \mathbb{P}(X \in W^* | H_0)$ е зададена, то W^* е ОКО (оптимална критична област).

Доказателство:

$$\underbrace{\alpha = \mathbb{P}(\vec{X} \in W^* | H_0) = \mathbb{P}(\vec{X} \in W | H_0)}_{\text{имаме}} \Rightarrow \underbrace{\mathbb{P}(\vec{X} \notin W^* | H_1) \leq \mathbb{P}(\vec{X} \notin W | H_1)}_{\text{искаме да докажем}}$$



$$\begin{aligned} \mathbb{P}(\vec{X} \notin W | H_1) &\stackrel{\theta=\theta_1}{=} \int_{\bar{W}} L_1(x) dx \\ &= \int_A L_1(x) dx + \int_C L_1(x) dx + \underbrace{\int_B L_1(x) dx - \int_B L_1(x) dx}_{=0} \\ &= \int_{\bar{W}^*} L_1(x) dx + \int_A L_1(x) dx - \int_B L_1(x) dx \\ &= \mathbb{P}(\vec{X} \in W^* | H_1) + \underbrace{\int_A L_1(x) dx - \int_B L_1(x) dx}_{\geq 0} \\ &\geq \mathbb{P}(\vec{X} \notin W^* | H_1), \text{ което искаме да докажем.} \end{aligned}$$

Тоест всичко се свежда до това да проверим, че $\int_A L_1(x) dx - \int_B L_1(x) dx \geq 0$, но

$$\int_A L_1(x) dx - \int_B L_1(x) dx \geq \underbrace{k \int_A L_0(x) dx - k \int_B L_0(x) dx}_{\stackrel{?}{=} 0}$$

$$\begin{aligned} \alpha &= \int_{W^*} L_0(x) dx = \int_A L_0(x) dx + \cancel{\int_D l_0(x) dx} \\ &= \int_W L_0(x) dx = \int_B L_0(x) dx + \cancel{\int_D L_0(x) dx} \\ &\Rightarrow \int_A L_0(x) dx = \int_B L_0(x) dx. \end{aligned}$$